

(19) 대한민국특허청(KR)
(12) 공개특허공보(A)

(11) 공개번호 10-2025-0124869

(43) 공개일자 2025년08월20일

(51) 국제특허분류(Int. Cl.)

G16C 60/00 (2019.01) G06N 3/044 (2023.01)

G06N 3/045 (2023.01) G06N 3/048 (2023.01)

G06N 3/0499 (2023.01) G06N 3/088 (2023.01)

G06N 3/09 (2023.01) G06N 3/092 (2023.01)

G06N 3/0985 (2023.01) G16C 20/30 (2019.01)

G16C 20/70 (2019.01)

(52) CPC특허분류

G16C 60/00 (2019.02)

G06N 3/044 (2023.01)

(21) 출원번호 10-2025-7023914

(22) 출원일자(국제) 2023년12월19일

심사청구일자 2025년07월16일

(85) 번역문제출일자 2025년07월16일

(86) 국제출원번호 PCT/EP2023/086654

(87) 국제공개번호 WO 2024/133271

국제공개일자 2024년06월27일

(30) 우선권주장

22215219.1 2022년12월20일

유럽특허청(EPO)(EP)

(71) 출원인

보레알리스 아게

오스트리아 1020 비엔나 트라브렌스트라쎄 6-8

(72) 발명자

토레스, 주안 파블로

오스트리아, 4021 린츠, 세인트 피터-스트라세

25, 씨/오 보레알리스 폴리올레핀 게엠베하

제라벡, 미카엘

오스트리아, 4021 린츠, 세인트-피터-스트라세

25, 씨/오 보레알리스 폴리올레핀 게엠베하

(뒷면에 계속)

(74) 대리인

특허법인천문


전체 청구항 수 : 총 14 항

(54) 발명의 명칭 하나 이상의 물질의 적어도 탄소성 기계적 응답을 나타내는 파라미터 값을 출력하기 위한 컴퓨터로 구현되는 방법

(57) 요약

여기에 개시된 본 발명은 하나 이상의 물질, 바람직하게는 하나 이상의 폴리머의 적어도 탄소성 기계적 응답을 나타내는 파라미터 값을 출력하기 위한 컴퓨터로 구현되는 방법에 관한 것이다. 본 발명은 프로세서에 의해 실행될 수 있는 컴퓨터 프로그램 명령어들을 유형으로 저장하는 비일시적 컴퓨터 판독 가능 저장매체에 관한 것이기도 한데, 상기 컴퓨터 프로그램 명령어들은 본 명세서에 설명된 파라미터 값 출력을 위한 컴퓨터로 구현되는 방법의 하나 이상의 단계의 단계들을 정의한다.

대표도 - 도1



(52) CPC특허분류

G06N 3/045 (2023.01)
G06N 3/048 (2023.01)
G06N 3/0499 (2023.01)
G06N 3/088 (2023.01)
G06N 3/09 (2023.01)
G06N 3/092 (2023.01)
G06N 3/0985 (2023.01)
G16C 20/30 (2019.02)
G16C 20/70 (2019.02)

(72) 발명자

루에다, 페데리코

아르헨티나, 씨피 7600, 부에노스 아이레스, 마르
델 플라타, 알마푸에르테 4016

키하스, 플로리안

오스트리아, 4040 린츠, 알텐베르거스트라세 69,
쾰/오 제이케이유 린츠

라이터, 마르틴

오스트리아, 4040 린츠, 알텐베르거스트라세 69,
쾰/오 제이케이유 린츠

명세서

청구범위

청구항 1

하나 이상의 물질, 바람직하게는 하나 이상의 폴리머의 적어도 탄소성 기계적 응답을 나타내는 파라미터 값을 출력하기 위한 컴퓨터로 구현되는 방법(100)에 있어서,

- 기계적 충격 시험에서 도출된 하나 이상의 실험적 힘-변위 신호의 데이터 값 세트를 최적화 알고리즘(102)에 입력하는 단계(101);

- 상기 최적화 알고리즘(102)을 통해, 하나 이상의 물성에 해당하는 물질 모델의 파라미터 값 조합(301)을 서치하는 단계(103, 104) - 이 파라미터 값 조합(301)은 상기 입력 단계(101)에서 입력된 데이터 값 세트와 이 파라미터 값의 예측값(107) 간에 차이를 발생시키는데, 상기 예측값은 하나 이상의 기계적 시험을 기반으로 한 유한 요소 시뮬레이션(Finite Element simulations)으로 학습된 인공 신경망(200)에 의해 바람직하게 수행되는 추정치에 기초한 것임 -; 및

- 상기 최적화 알고리즘(102)으로부터, 상기 입력 단계(101)에서 입력된 데이터 값 세트와 상기 인공 신경망(200)에 의해 수행되는 유한 요소 시뮬레이션 또는 그 추정치 간의 사전 정의된 최소 차이를 발생시키는 파라미터 값을 출력하는 단계(108)

를 포함하는,

컴퓨터로 구현되는 방법(100).

청구항 2

제1항에 있어서,

상기 출력 단계(108) 전에, 하나 이상의 신경 처리 유닛을 포함하는 상기 학습된 인공 신경망을 이용하여 하나 이상의 힘-변위 신호를 예측하는 단계(107) 및 구성 모델(constitutive model)에 해당하는 물성을 상기 학습된 인공 신경망을 통해 상기 하나 이상의 기계적 충격 시험에 기초한 데이터 값 세트에 매핑하는 단계를 더 포함하는,

컴퓨터로 구현되는 방법(100).

청구항 3

제1항 또는 제2항에 있어서,

출력 파라미터 값은 적어도 하나의 변형률-속도-의존적 기계적 응답(strain-rate-dependent mechanical response) 및/또는 온도 의존적 기계적 응답(temperature dependent stiffness)을 나타내고, 바람직하게는 상기 적어도 하나의 변형률-속도-의존적 기계적 응답 및/또는 상기 적어도 하나의 온도 의존적 기계적 응답은 상기 최적화 알고리즘에 반영되는(accounted),

컴퓨터로 구현되는 방법(100).

청구항 4

제1항 내지 제3항 중 어느 한 항에 있어서,

상기 학습된 인공 신경망(200)은 하나 이상의 피드 포워드 멀티-레이어-퍼셉트론 신경망 모델(feed forward multi-layer-perceptron neural network models)을 포함하며, 각각의 기계적 시험마다 고유의 하이퍼파라미터(hyperparameters)를 갖는 자체 신경망 모델이 생성되며, 각각의 모델은 적어도 두 개의 은닉 뉴런 계층들(hidden layers of neurons)(202)을 갖는,

컴퓨터로 구현되는 방법(100).

청구항 5

제1항 내지 제4항 중 어느 한 항에 있어서,

상기 하나 이상의 기계적 테스트는,

- 계측 샤르피 충격 시험(instrumented Charpy impact test);
- 계측 아이조드 충격 시험(instrumented Izod impact test);
- 계측 천공 시험(instrumented puncture test);
- 계측 낙하 중량 시험(instrumented falling weight test); 및/또는
- 서로 다른 온도에서의 인장 시험(tensile test)인,

컴퓨터로 구현되는 방법(100).

청구항 6

제1항 내지 제5항 중 어느 한 항에 있어서,

상기 인공 신경망(200)은, 하나 이상의 기계적 특성을 해당 힘-변위 신호에 매핑하기 위해, 다수의 유한 요소 시뮬레이션의 데이터베이스로부터 얻는 데이터로 학습되는,

컴퓨터로 구현되는 방법(100).

청구항 7

제1항 내지 제6항 중 어느 한 항에 있어서,

입력 데이터 값 세트는 적어도 하나의 멀티-포인트 힘-변위 신호 형태의 수치 데이터 세트이며, 바람직하게는 탄성 데이터(elasticity data), 소성 데이터(plasticity data), 속도-의존적 항복 데이터(rate-dependent yield data), 손상 데이터(damage data), 및/또는 파괴 데이터(failure data) 중 하나 이상에 해당하는,

컴퓨터로 구현되는 방법(100).

청구항 8

제1항 내지 제7항 중 어느 한 항에 있어서,

상기 방법은 상기 입력 단계(101) 전에 입력 데이터 값의 개수를 줄이는 특징화(featurization) 단계를 포함하고, 바람직하게는 다음의 파라미터들 중 하나 이상이 상기 입력 데이터 값에 해당하는, 컴퓨터로 구현되는 방법(100):

- 한계 하중(limit load) (F_{max});
- 처짐(deflection) (U_{max});
- 최대 하중(peak load) (E_{br})의 힘 강하(force drop);
- 0.05% 내지 0.25%의 변형률 구간에서 최소제곱 회귀(least squares regression)에 해당하는 기울기(E); 및/또는
- 항복점에서의 응력(stress at yield point) (σ_y).

청구항 9

제1항 내지 제8항 중 어느 한 항에 있어서,

상기 물성은 열-점탄성-점소성 모델로 나타내고, 상기 파라미터 값은 바람직하게는 다음 중 하나 이상인, 컴퓨터로 구현되는 방법(100):

- 특정 형상(specific geometry);

- 온도;
- 변형률 속도 의존적 강성(strain rate dependent stiffness);
- 항복(yield); 및
- 파괴 변형률(failure strain).

청구항 10

제1항 내지 제9항 중 어느 한 항에 있어서,

출력되는 상기 파라미터 값은 적어도 하나의 고유 물성(intrinsic material property)을 포함하고, 출력되는 상기 파라미터 값은 입력 데이터 값 세트를 벗어난 조건에서의 물성 예측에 적합한 특징(features)을 나타내는, 컴퓨터로 구현되는 방법(100).

청구항 11

제2항 내지 제10항 중 어느 한 항에 있어서,

상기 구성 모델은 탄성 또는 소성에 대한 비선형 모델을 기반으로 하며, 바람직하게는 파괴 파라미터 보정(failure parameter calibration)이 있는,

컴퓨터로 구현되는 방법(100).

청구항 12

제2항 내지 제10항 중 어느 한 항에 있어서,

상기 구성 모델은 다음의 모델들 중 하나 이상인, 컴퓨터로 구현되는 방법(100):

- Hooke 법칙에 기반한 선형 탄성 모델;
- 선형 점탄성 모델;
- 초탄성(hyperelasticity) 모델;
- 선형 탄성 등방성 변형률 경화 소성 모델;
- ABAQUS 완전 소성 모델;
- ABAQUS 등방성 경화 모델;
- ABAQUS 운동학적 경화 모델;
- Johnson-Cook 등방성 경화 모델;
- Drucker-Prager 모델;
- Mohr-Coulomb 소성 모델;
- 크러셔블 폼(crushable foam) 소성 모델;
- Ramberg-Osgood 소성 모델;
- LS-DYNA MAT_24 모델;
- ABAQUS 시험 데이터 직접 입력 모델;
- ABAQUS 2층 점소성 모델;
- ABAQUS 항복 응력 비율 모델;
- Johnson-Cook 속도 의존 모델;
- Bergstrom-Boyce 모델;
- Bergstrom Three Network 모델;

- Bergstrom Hybrid 모델;
- LS-DYNA SAMP-1 모델;
- ABAQUS 연성 금속의 점진적 손상 및 파괴 모델;
- ABAQUS 섬유-강화 물질의 점진적 손상 및 파괴 모델;
- LS-DYNA 모델.

청구항 13

제1항 내지 제12항 중 어느 한 항에 있어서,
상기 하나 이상의 실험적 힘-변위 신호는 충격 하중 실험 때 기록된 것인,
컴퓨터로 구현되는 방법.

청구항 14

프로세서에 의해 실행될 수 있는 컴퓨터 프로그램 명령어들을 유형으로(tangibly) 저장하는 비일시적 컴퓨터 판독 가능 저장매체에 있어서,

상기 컴퓨터 프로그램 명령어들은 제1항 내지 제13항의 방법 청구항들 중 어느 한 항의 단계들을 정의하는,
비일시적 컴퓨터 판독 가능 저장매체.

발명의 설명

기술 분야

[0001] 여기에 개시된 본 발명은 하나 이상의 물질, 특히 하나 이상의 폴리머의 적어도 탄소성 기계적 응답(elastoplastic mechanical response)을 나타내는 파라미터 값을 출력하기 위한 컴퓨터로 구현되는 방법에 관한 것이다. 또한, 본 발명은 프로세서에 의해 실행될 수 있는 컴퓨터 프로그램 명령어들을 유형으로(tangibly) 저장하는 비일시적 컴퓨터 판독 가능 저장매체에 관한 것인데, 상기 컴퓨터 프로그램 명령어들은 본 명세서에 설명된 파라미터 값의 출력을 위한 컴퓨터로 구현되는 방법의 하나 이상의 단계의 단계들을 정의한다.

[0002] 더욱 구체적으로, 충격 시험을 통해 얻어지는 하나 이상의 힘-변위 신호(force-displacement signals)와 같은 복잡한 정보 소스로부터 물성을 추출하는 방법론이 여기에 소개되는데, 상기 충격 시험으로는 예를 들어, 계측 샤르피(Charpy) 충격 시험; 및/또는 계측 아이조드(Izod) 충격 시험; 및/또는 계측 천공 시험; 및/또는 계측 낙하 중량 시험 또는 임의의 테스트 시편에 동적 하중을 가하는 그 밖의 다른 기계적 충격 시험 같은 것들이 있다.

배경 기술

[0003] 자동차 산업에서 이용되는 공급망과 같은 현대 공급망에서, 주문자 상표에 의한 제품 생산자(OEMs) 및 이들의 공급업체들은 자사 제품의 부품 및 구성요소를 설계 및 제조하기 위해 고유 물성 데이터를 요구하고 이를 활용한다. 이러한 맥락에서, 하나 이상의 충격 하중 조건에서의 물질 거동을 나타낼 수 있는 물성 데이터를 생성하는 것에 대한 요구가 점점 더 커지고 있는데, 고급 어플리케이션일수록 특히 그러하다.

[0004] WO 2021/110690 A1은 테스트 노력을 줄이기 위해 폼(foam) 샘플의 이미지로부터 물성을 결정하는 방법을 개시하고 있다. 여기에서는, 이미지로부터 구조적 특징이 측정되되 특히 미시적 수준에서의 구조적 특징, 즉 기공(pore), 벽(wall), 스트럿(strut), 노드(node), 셀(cell) 등과 같은 미세 구조 특징이 측정되고, 이렇게 측정된 구조적 특징이 물질 모델(material model)로 제공된다. 상기 물질 모델은 학습된 머신 러닝 모델과 같은 데이터 기반 모델인데, 이것은 물리 법칙에 대한 지식 없이도 상기 구조적 특징을 물성과 연관시킨다. 여기서는, 구조적 특징이 이미지로부터 직접 측정된다. 이러한 측정은 상기 방법의 복잡성을 증가시키는 추가적인(고가의) 장비를 필요로 한다. 또한, 측정 과정의 결과와 그 오차를 입력 파라미터로서 적합하도록 변환해야 한다. 이러한 변환은 정확도를 떨어뜨리고 상기 방법의 복잡성을 더욱 증가시킨다. 상기 테스트 결과로부터는 고유 물성 정보가 도출될 수 없다.

[0005] US 10,955,362 B2는 폴리머의 품질을 실시간으로 결정하는 방법을 개시하고 있다. 이 방법에서는, 폴리머 샘플

의 라만 스펙트럼(Raman spectrum)을 획득하고, 머신 러닝 툴을 이용하여 화학적 및/또는 구조적 지문(fingerprint)을 이전에 저장된 물성 데이터와 비교함으로써 폴리머의 물성/특성을 산출한다. 상기 머신 러닝 툴의 알고리즘은 기존 방법으로 실험실에서 측정된 알려진 샘플들의 폴리머 물성/특성과 과거 라만 데이터로 학습된다. 원하는 폴리머 물성에 대해, 측정된 폴리머 물성/특성과 해당 라만 스펙트럼 데이터를 포함하는 데이터 세트가, 어플리케이션 프로그래밍 인터페이스(API)를 통해 접근 가능한 데이터베이스에 입력된다. 이 방법에서는, 구조적 특징이 직접 측정되며, 라만 스펙트럼을 기록하여야 한다. 이러한 측정과 데이터 제공은 추가적인(고가의) 장비를 필요로 하며 상기 방법의 복잡성을 증가시킨다. 상기 테스트 결과로부터는 고유한 기계적 특성 정보가 도출될 수 없다.

[0006] 이러한 모든 공지된 개념들의 단점은 제공되는 정보가 부족하다는 것이다. 이러한 불충분한 정보로는 온도-의존적 및 변형률-속도-의존적 강성, 항복 응력, 및/또는 파괴 변형률과 같은 고유한 기계적 특성을 결정할 수 없다.

[0007] 예를 들어, 물질의 변형 능력은 하중 조건에 따라 달라질 수 있다. 따라서, 물질의 변형 거동에 대한 지식은 물질 평가 또는 물질 선정에 있어 중요한 기준이 된다. 많은 경우에, 일반적인 강도 시험(예를 들어, 정적 인장 시험)에서는 요구사항을 충족하는 물질이라도 다축 하중 및 저온 조건에서의 취성 파괴로 인해 실제로 사용될 때는 파손될 수 있다는 것이 밝혀졌다.

[0008] 연성(인성), 강성, 및 취성은 물질에 따라 다를 뿐만 아니라 응력 상태, 변형속도 및 온도와 같은 하중 조건들에 따라서도 달라진다. 이러한 종속성으로 인해 그리고 엔지니어링 실무에서의 다축 하중 및/또는 충격 하중 발생으로 인해, 물질의 기계적 응답은 온도-의존적 및 속도-의존적 탄소성 물질 모델(열-점탄성-점소성 물질 모델로도 지칭됨)을 통해서만 정확하게 나타낼 수 있다.

[0009] 예를 들어, 자동차 산업에서 사용되는 제품, 부품, 및 물질은 예를 들어 -30°C 내지 $+120^{\circ}\text{C}$ 와 같은 넓은 온도 범위에서 일정하고 안정적이어야 한다. 그러나, 기계적 특성, 특히 폴리머의 기계적 특성은 온도 변화에 매우 의존적이고 민감할 수 있다. 예를 들어, 폴리(메틸 메타크릴레이트)는 4°C 의 온도에서 취성 물질로 알려져 있지만, 더 높은 온도에서는 연성 거동이 우세하다.

[0010] 알려진 개념들은 시험 결과를 제공하는데 엄청난 시간과 연산 자원을 필요로 한다는 점도 문제로 여겨져 왔다.

[0011] 따라서, 물질 파라미터를 결정하고 충격 하중을 받는 하나 이상의 물질의 적어도 탄소성 기계적 응답을 나타내는 물질 파라미터를 더 정확하고, 덜 복잡하며, 더 효율적인 자동화된 방식으로 출력할 수 있는 방법이 필요하다. 구체적으로, 출력되는 물질 파라미터는 동적 물질 응답을 얻기 위해 고유 물성을 나타내야 하는데, 상기 동적 물질 응답은 예를 들어 물질(들)의 변형률-속도-의존적 및 온도-의존적 기계적 응답도 포함한다.

발명의 내용

[0012] 위에서 언급된 문제점 및 필요성은 독립항의 특징들에 의해 해결된다. 종속항들로부터는 유리한 실시예들이 도출될 수 있다.

[0013] 일 측면에서, 하나 이상의 물질의 적어도 탄소성 기계적 응답을 나타내는 파라미터 값을 출력하기 위한 컴퓨터로 구현되는 방법이 개시된다. 상기 방법은, 기계적 충격 시험에서 도출된 하나 이상의 실험적 힘-변위 신호의 데이터 값 세트를 최적화 알고리즘에 입력하는 단계; 상기 최적화 알고리즘을 통해, 하나 이상의 물성을 나타내는 물질 모델의 파라미터 값 조합을 서치하는 단계 - 이 파라미터 값 조합은 상기 입력 단계에서 입력된 데이터 값 세트와 이 파라미터 값의 예측값 간에 차이를 발생시키는데, 상기 예측값은 하나 이상의 기계적 시험을 기반으로 한 유한 요소 시뮬레이션(Finite Element simulations)으로 학습된 인공 신경망에 의해 바람직하게 수행되는 추정에 기초한 것임 -; 및 상기 최적화 알고리즘으로부터, 상기 입력 단계에서 입력된 데이터 값 세트와 상기 인공 신경망에 의해 수행되는 유한 요소 시뮬레이션 또는 그 추정값 간의 사전 정의된 최소 차이를 발생시키는 파라미터 값 조합을 출력하는 단계를 포함한다.

[0014] 다시 말해, 하나 이상의 물질의 적어도 탄소성 기계적 응답을 나타내는 파라미터 값을 출력하기 위한 본 발명에 따른 컴퓨터로 구현되는 방법은, 기계적 충격 시험에서 도출된 하나 이상의 실험적 힘-변위 신호의 데이터 값 세트를 최적화 알고리즘에 입력하는 단계; 상기 최적화 알고리즘을 통해, 하나 이상의 물성을 나타내는 물질 모델의 파라미터 값 조합을 서치하는 단계 - 이 파라미터 값 조합은 하나 이상의 기계적 시험을 기반으로 한 유한 요소 시뮬레이션으로 학습된 인공 신경망에 의해 바람직하게 수행되는 추정에 기초한 예측값과 상기 입력 단계에서 입력된 데이터 값 세트 간에 차이를 발생시킴 -; 및 상기 최적화 알고리즘으로부터, 상기 입력 단계에서

입력된 데이터 값 세트와 상기 인공 신경망에 의해 수행되는 유한 요소 시뮬레이션 또는 그 추정값 간의 사전 정의된 최소 차이를 발생시키는 파라미터 값을 출력하는 단계를 포함한다.

[0015] 본 발명에 따른 컴퓨터로 구현되는 방법은 하나 이상의 물질의 적어도 탄소성 기계적 응답을 나타내는 파라미터 값을 출력하는 방법으로 지칭될 수도 있는데, 상기 방법은, 하나 이상의 기계적 시험에서 도출된 하나 이상의 실험적 힘-변위 신호의 데이터 값 세트를 최적화 알고리즘에 입력하는 단계; 상기 최적화 알고리즘을 통해 물질 모델의 파라미터 값 조합을 서치하는 단계 - 상기 파라미터 조합은 하나 이상의 물성을 나타내고, 상기 파라미터 값 조합은 상기 입력 단계에서 입력된 데이터 값 세트와 상기 파라미터 값 조합에 기반한 예측값 간의 차이를 발생시키는데, 바람직하게는 상기 예측값은 하나 이상의 기계적 시험을 기반으로 한 유한 요소 시뮬레이션으로 바람직하게 학습된 인공 신경망을 통해 획득됨 -; 및 상기 최적화 알고리즘으로부터, 상기 입력 단계에서 입력된 데이터 값 세트와 인공 신경망에 의해 수행되는 유한 요소 시뮬레이션 또는 그 추정값 간의 사전 정의된 최소 차이를 발생시키는 파라미터 값 조합을 출력하는 단계를 포함한다.

[0016] 또한 달리 말하면, 하나 이상의 물질의 적어도 탄소성 기계적 응답을 나타내는 파라미터 값을 출력하기 위한 본 발명에 따른 컴퓨터로 구현되는 방법은, 하나 이상의 기계적 충격 시험에서 실험적으로 획득된 하나 이상의 힘-변위 신호의 데이터 값 세트를 최적화 알고리즘에 입력하는 단계; 상기 최적화 알고리즘을 통해 물질 모델의 파라미터 값 조합을 서치하는 단계 - 상기 파라미터 조합은 하나 이상의 물성을 나타냄 -; 상기 입력 단계에서 입력된 데이터 값 세트와 상기 파라미터 값 조합에 기반한 예측값 간의 차이를 연산하는 단계; 및 상기 최적화 알고리즘으로부터, 상기 입력 단계에서 입력된 데이터 값 세트와 상기 예측값 간의 사전 정의된 최소 차이를 발생시키는 파라미터 값 조합을 출력하는 단계를 포함하되, 상기 예측값은 상기 파라미터 값 조합에 기반하여 인공 신경망에 의해 수행되는 유한 요소 시뮬레이션 또는 그 추정의 결과이다. 이 방법에서, 상기 서치 단계 및 상기 차이 연산 단계는 상기 최적화 알고리즘에서 반복적으로 수행되는 것이 바람직하다.

[0017] 또한, 하나 이상의 물질의 적어도 탄소성 기계적 응답을 나타내는 파라미터 값을 출력하기 위한 본 발명에 따른 컴퓨터로 구현되는 방법은 다음의 단계들을 포함하는 것으로 정의될 수 있다: 하나 이상의 기계적 시험에서 도출된 하나 이상의 실험적 힘-변위 신호의 데이터 값 세트를 최적화 알고리즘에 입력하는 단계; 상기 최적화 알고리즘을 통해 물질 모델의 파라미터 값 조합을 서치하는 단계 - 상기 파라미터 조합은 하나 이상의 물성을 나타냄 -; 상기 입력 단계에서 입력된 데이터 값 세트와 상기 파라미터 값 조합에 기반한 예측값 간의 차이를 연산하는 단계 - 상기 예측값은 인공 신경망에 의해 수행되는 유한 요소 시뮬레이션 또는 그 추정의 결과임 -; 및 상기 최적화 알고리즘으로부터, 사전 정의된 최소 차이를 발생시키는 파라미터 값 조합을 출력하는 단계. 이 방법에서, 상기 서치 단계 및 상기 차이 연산 단계는 상기 최적화 알고리즘에서 반복적으로 수행되는 것이 바람직하다.

[0018] 따라서, 지능형 최적화 기법, 바람직하게는 다목적 최적화 알고리즘[예를 들어, 유전 알고리즘(GA)에 기반한]을 수행하여, 상기 입력된 세트의 값을 예측에 최적 적합(사전 정의된 최소 차이)시키는 파라미터 값 또는 특성의 조합을 서치하는데, 상기 예측은 예를 들어 이 최적-적합(best-fit) 출력 파라미터들을 이용하여 시뮬레이션된 실험 곡선이다. 이러한 최적화는 상기 출력 파라미터의 정확성을 더욱 높이고 상기 방법의 속도를 더욱 향상시키기 위하여 상기 방법에 통합된다.

[0019] 이 최적화 알고리즘은 비교 단계를 이용하는 최적화 루프로 구성될 수 있는데, 여기서는 상기 입력된 데이터 세트가 인공지능 신경망에 의해 수행되는 (초기) 예측과 비교된다. 이후, 상기 최적화 알고리즘은 하나 이상의 종료 기준(stopping criteria)(예를 들어, 최소 차이)에 도달하였는지의 여부를 판단한다. 상기 종료 기준/기준들에 도달하지 않았다면, 상기 최적화 알고리즘에서 또다른 루프(라운드)가 수행되고 상기 비교 및 판단 단계들이 반복된다. 상기 종료 기준/기준들에 도달하였다면, 상기 최적화 알고리즘이 종료되고, 이 종료를 유발한 출력 파라미터 값은 하나 이상의 물질의 적어도 탄소성 기계적 응답을 나타내기 위해 사용된다. 상기 하나 이상의 물질의 탄소성 기계적 응답은 상기 기계적 충격 테스트에서 도출된 하나 이상의 실험적 힘-변위 신호의 입력 데이터 값 세트를 초래할 것이다.

[0020] 상기 최적화 기법은 (파라미터) 최적화 과정에서 외부 식(external equations)을 활용할 수 있다. 상기 최적화 기법(최적화 알고리즘)은 NSGAII 유전 알고리즘(예를 들어, Platypus Python 라이브러리로부터의)을 사용할 수 있다.

[0021] 결과적으로, 인공 신경망과 다목적 최적화 기법을 기반으로 보정된 열-점탄성-점소성 물질 모델(thermo-viscoelastic-viscoplastic material model)이 얻어진다.

- [0022] 바람직한 실시예에서, 상기 방법은, 상기 출력 단계 전에, 하나 이상의 신경 처리 유닛을 포함하는 상기 학습된 인공 신경망을 이용하여 하나 이상의 힘-변위 신호를 예측하는 단계 및 구성 모델(constitutive model)을 나타내는 물성을 상기 학습된 인공 신경망을 통해 상기 하나 이상의 기계적 충격 시험에 기초한 데이터 값 세트에 매핑하는 단계를 더 포함한다.
- [0023] 바람직한 실시예에서, 출력 파라미터 값은 적어도 하나의 변형률-속도-의존적 기계적 응답 및/또는 온도 의존적 기계적 응답을 나타낸다. 상기 적어도 하나의 변형률-속도-의존적 기계적 응답 및/또는 상기 적어도 하나의 온도 의존적 기계적 응답은 바람직하게는 아래에서 설명되는 바와 같이 최적화 알고리즘에 반영된다.
- [0024] 기계적 충격 시험은 충격 하중 하에서 물질의 응답을 추출하는데 사용되는 것으로 알려져 있지만, 이러한 시험으로부터 직접적으로 얻어지는 정보만으로는 온도 의존적 및 변형률-속도 의존적 강성, 항복 응력 및 파괴 변형률과 같은 고유 물성들을 알아낼 수 없다. 이제, 본 발명의 솔루션을 통해, 충격 하중 하에서 물질의 변형률-속도-의존적 및 온도-의존적 기계적 응답을 나타내는 파라미터를 자동으로 알아낼 수 있다.
- [0025] 결과적으로, 인공 신경망을 기반으로 보정된 열-점탄성-점소성 물질 모델이 얻어진다.
- [0026] 입력 데이터 값은 하나 이상의 기계적 충격 시험으로부터 얻어지지만, 상기 서지 단계 및/또는 상기 매핑 단계는 하나 이상의 기계적 충격 시험을 기반으로 수행될 수 있다. 이와 관련하여, 상기 학습된 인공 신경망은 복수의 신경 모델들을 포함할 수 있는데, 이들 각각은 서로 다른 기계적 충격 시험에 해당한다. 이 매핑 단계를 통해, 시간이 많이 소요되고 시뮬레이션의 추가적 반복 과정에서 파라미터 조정이 필요할 수도 있는 유한 요소(FE) 시뮬레이션의 실시간 연산을 피할 수 있고, 따라서 출력 파라미터를 훨씬 빠르게 도출할 수 있다.
- [0027] 여기에서는, 학습된 인공 신경망을 통합하여 일반적으로 요구되는 FE 시뮬레이션을 대체함으로써 출력 파라미터를 얻는데 걸리는 연산 시간을 획기적으로 단축할 수 있는데, 예를 들어 수십 배 이상 단축할 수 있다. 여기에서는, 하나 이상의 기계적 시험의 결과를 포함할 수 있는 입력 데이터 값에 물성이 매핑될 수 있다. 이러한 새로운 셋업을 통해, 상기 방법이 커버할 수 있는 온도, 변형률-속도 및 형상 조건의 범위가 확장될 수 있으며, 따라서 그 적용 범위 및 정확성이 증가한다.
- [0028] 이 방법은 하나 이상의 탄소성 기계적 응답(들)을 나타내는 파라미터 값을 제공하며, 물질의 온도 의존성 및 변형률-속도 의존성을 반영하는 추가 모델을 더 사용할 수 있다. 이를 통해, 고유 물성을 나타내는 기본 물리 법칙에 대한 정보를 얻을 수 있고, 따라서 이러한 출력 파라미터를 기반으로 하는 또 다른 추가적 평가 및 시험에서 더 높은 가치를 갖는다.
- [0029] 이것은, 제공된 이 솔루션이 (상기 학습된 인공 신경망 덕분에) 출력 파라미터를 훨씬 더 빠르고 신뢰성 있게 제공한다는 것을 의미한다.
- [0030] 본 발명의 핵심 개념은, 하나 이상의 물질(들)의 기계적 충격 거동을 가장 잘 나타내는 물질 파라미터 값이, 이 물질에 대한 기계적 충격 시험의 시뮬레이션 수행을 위해 사용될 때 이러한 시뮬레이션과 상기 실험적 입력 데이터 간의 차이가 최소가 되도록 하는 파라미터 값이라는 점이다. 최적-적합 결과를 얻기 위해 반복 작업이 필요한 경우와 같이 시간 소모가 큰 시뮬레이션을 수행하는 것을 피하기 위해 이제 이러한 시뮬레이션을 학습된 인공 신경망으로 대체하는데, 상기 인공 신경망은 하나 이상의 기계적 충격 시험이 사용된 이 FE 시뮬레이션의 데이터베이스로부터 학습되고, 연산 속도가 최소 열 배 이상 빠른 대리 모델(surrogate model)로서의 역할을 한다.
- [0031] 더욱 구체적으로, 이는 실험 데이터(데이터 값 세트)를 상기 학습된 인공 신경망에 입력함으로써 달성되는데, 상기 학습된 인공 신경망은 컴퓨터 프로그램 제품의 일부이며, 기계적 특성을 하나 이상의 충격 하중 실험/시험 동안 기록된 해당 힘-변위 신호에 매핑하도록 사전에 학습되어 있다. 출력 값은 물질 모델의 구성 파라미터, 즉 물질의 기계적 특성이다.
- [0032] 따라서, 본 발명은 입력으로 제공된 실험 조건을 벗어난 조건에서도 물질 거동을 예측하는데 이용될 수 있는 물질 데이터를 생성한다. 이 정보는 컴퓨터 지원 시뮬레이션(예를 들어, 유한 요소 분석 등을 이용하는)을 통해 새로운 부품 또는 구성요소를 설계하는데 특히 유용하고, 상이한 물질들을 기계적 특성에 대한 특정 값 측면에서 비교하는데 특히 유용하다.
- [0033] 이 방법을 이용하면, 특정 하중 시나리오 및 임의의 하중 시나리오에서(더욱 정확히는, 기계적 충격 하중에서) 그리고 다양한 부품 형상, 온도 및 변형률 속도에 대해) 물질 응답을 예측 가능하게 하는 툴(tool)을 제공함으로써 엔지니어가 새로운 물질, 부품 및 구성요소를 개발하는데 도움을 줄 수 있다.

- [0034] 바람직한 실시예에서, 상기 학습된 인공 신경망은 하나 이상의 피드 포워드 멀티-레이어-퍼셉트론 신경망 모델(feed forward multi-layer-perceptron neural network models)을 포함하며, 각각의 기계적 충격 시험마다 고유의 하이퍼파라미터(hyperparameters)를 갖는 자체 신경망 모델이 생성되며, 각각의 모델은 적어도 두 개의 은닉 뉴런 계층들(hidden layers of neurons)을 갖는다. 이를 통해, 상기 방법은 최고의 성능을 발휘할 수 있으며, 서로 다른 충격 시험들이 서로 다른 신경 모델들을 이용하여 적용될 수 있다. 이 신경 모델들을 병렬로 실행하고 시험 결과들을 결합하여 최적-적합 출력 파라미터를 도출할 수 있다.
- [0035] 상기 멀티-레이어-퍼셉트론 신경망은 Scikit-Learn Python 라이브러리를 사용하여 구현될 수 있다.
- [0036] 상기 하나 이상의 기계적 테스트는 고속(high-velocities) 또는 비-준정적(non quasi-static) 조건에서 수행되는 임의의 기계적 테스트일 수 있다.
- [0037] 상기 하나 이상의 기계적 시험은 예를 들어 고속 인장 시험 또는 고속 3점(또는 4점) 굽힘 시험; 및/또는 계측 샤르피 충격 시험(예를 들어, ISO-표준 179-2:2020에 따른), 및/또는 계측 하이조드 충격 시험(예를 들어, ASTM 표준 D256 또는 ISO-표준 180에 따른), 및/또는 계측 천공 시험(예를 들어, ISO-표준 6603-2:2002-04에 따른), 및/또는 계측 낙하 중량 시험, 및/또는 인장 시험일 수 있는데, 각각의 시험은 바람직하게는 서로 다른 온도들에서 수행된다.
- [0038] 샤르피 충격 시험은 샤르피 V-노치 시험으로도 알려져 있는 노치-충격 시험(notched-impact test) 또는 비-노치 샤르피 충격 시험(unnotched Charpy impact test)일 수 있으며, 물질이 파단(fracture)될 때 흡수하는 에너지 양을 측정하는 표준화된 고변형률 속도 시험이다. 흡수된 파단 에너지는 물질의 인성(toughness)을 평가하는 지표로 자주 사용된다. 이 시험은 수행하기 쉽고, 비교적 저렴한 비용으로 신속하게 결과를 얻을 수 있기 때문에 산업계에서 널리 활용되고 있다. 샤르피 충격 시험을 수행하는 장치는 질량과 길이가 알려진 진자(pendulum)를 포함하는데, 물질의 프로브(probe)(샘플 또는 시편)에 충격을 가하기 위해 상기 진자를 알려진 높이에서 떨어뜨린다. 물질에 전달된 에너지는 파단 전후에 있어서 해머(hammer)의 높이 차이를 통해 추정할 수 있다. 상기 물질의 프로브는 V-형 노치를 포함한다. 샘플의 노치는 충격 시험 결과에 영향을 미치므로, 상기 노치는 표준적(regular) 치수 및 형상을 가져야 한다. 충격 시험은 물질의 인성을 측정하는데 사용될 수 있다. 또한, 물질의 파단에 필요한 에너지가 급격히 변하는 온도로부터 연성-취성 전이온도(DBTT)가 도출될 수 있다.
- [0039] 아이조드 충격 강도 시험으로도 지칭되는 아이조드 충격 시험은 물질의 충격 저항성을 측정하는 또 다른 표준 방법이다. 피봇 암(pivoting arm)을 특정 높이까지 올리고(일정한 위치 에너지), 이어서 놓는다. 암이 아래로 돌면서 노치가 있는 샘플을 타격하여 시편을 파괴한다. 암이 샘플을 타격한 후 돌아간 높이로부터 샘플이 흡수한 에너지를 연산한다. 노치가 있는 샘플은 일반적으로 충격 에너지와 노치 민감도를 측정하는데 사용된다. 아이조드 충격 시험은 샤르피 충격 시험과 유사하지만 시험 시편의 배치 방식이 다르다. 아이조드 충격 시험에서는 샘플이 캔틸레버 빔 형태(cantilevered beam configuration)로 고정되는 반면, 샤르피 충격 시험에서는 3점 굽힘 형태로 배치된다.
- [0040] 계측 천공 시험(IPT)은 주로 필름, 고무, 또는 종이인 샘플에 탐침을 이용하여 일정한 속도로 힘을 가했을 때 상기 샘플이 탐침에 의해 파열되는 것을 견디는 능력을 측정하는 것에 초점을 맞춘 시험 표준의 한 카테고리이다.
- [0041] 계측 낙하 시험 또는 드롭(drop) 시험[예를 들어, 낙하 중량 충격 시험 또는 닥트 드롭 충격 시험(DDI)]은 부품을 정해진 높이에서 정해진 표면으로 떨어뜨리는 기계적 시험이다.
- [0042] 바람직한 실시예에서, 상기 인공 신경망은 다수의 유한 요소(FE) 시뮬레이션의 데이터베이스로부터 얻는 데이터로 학습된다. 이 데이터베이스에는 다수의 데이터 항목들이 있을 수 있는데, 각 데이터 항목은 하나 이상의 기계적 시험(들)의 단일 시뮬레이션 시험 결과를 고정 매개변수화(fixed parameterization)를 이용하여 나타낼 수 있다. 이 데이터 항목은 하나 이상의 기계적 특성을 해당 힘-변위 신호에 매핑하는데 사용된다.
- [0043] 입력 데이터 값 세트는 적어도 하나의 멀티-포인트 힘-변위 신호 형태의 수치 데이터 세트이거나 이로부터 유래된 일련의 데이터 값일 수 있다.
- [0044] 상기 최적화 알고리즘을 위한 입력 데이터 값 세트는 탄성 데이터에 해당할 수 있다. 상기 탄성 데이터는 물질이 변형력에 저항하고 그 힘이나 하중이 제거되면 원래의 크기와 형태로 돌아가는 능력에 관한 정보를 포함할 수 있다. 고체 물체는 충분한 하중이 가해지면 변형된다; 물질이 탄성인 경우, 상기 물체는 하중이 제거되면 원래의 형태 및 크기로 돌아간다. 탄성 및 탄성률은 단위 면적당 힘으로 정의되며, 일반적으로 압력 측정값인데,

이것은 역학에서는 응력에 해당한다.

- [0045] 상기 최적화 알고리즘을 위한 입력 데이터 값 세트는 소성 데이터에 해당할 수 있다. 상기 소성 데이터는 가해지는 힘에 반응하여 물질이 비가역적 형태 변화인 영구적 변형을 일으키는 능력에 관한 정보를 포함할 수 있다. 따라서, 이것은 탄성과는 반대 개념이다.
- [0046] 물질의 탄성 거동에서 소성 거동으로의 전이를 항복(yielding)이라고 한다. 상기 입력 데이터 값 세트는 (속도-의존적) 항복 데이터에 해당할 수 있다. 상기 항복 데이터는 항복점에 대한 정보를 포함할 수 있는데, 이것은 응력-변형률 곡선 상에서 탄성 거동의 한계 및 소성 거동의 시작을 나타내는 점이다. 항복점 아래에서는, 물질이 탄성적으로 변형되고, 가해진 응력이 제거되면 원래의 형태로 되돌아간다. 그러나, 항복점을 일단 지나면, 변형의 일부는 영구적이면서 비가역적이 되는데, 이를 소성 변형이라고 한다.
- [0047] 속도-의존적 항복 데이터는 항복 강도가 변형률에 따라 달라지고 예상 변형률 속도가 큰 경우 물질의 항복 거동을 정확히 정의하기 위한 정보를 포함할 수 있다. 이 속도-의존적 항복 데이터는, 등방성 경화 금속 소성 모델(isotropic hardening plasticity models), 비선형 등방성/운동학적 소성 모델의 등방성 성분(isotropic component of nonlinear isotropic/kinematic plasticity models), 및 확장된 Drucker-Prager 소성 모델에 대한 표 형식의 데이터를 제공함으로써 가공 경화 파라미터(work hardening parameters) 및 필드 변수(field variables)를 기반으로 편리하게 정의될 수 있다. 또한, 상기 속도-의존적 항복 데이터는 사용자 정의 초과응력 거듭제곱 법칙 파라미터(user-defined overstress power law parameters), 항복 응력 비율, 또는 Johnson-Cook 속도 의존적 파라미터의 명시를 통해 정의될 수 있다. 상기 속도-의존적 항복 데이터는, 특히 동적 해석(dynamic analysis)에서, 변형률 속도가 증가함에 따라 항복 응력이 증가하도록 명시되어야 한다.
- [0048] 상기 최적화 알고리즘을 위한 입력 데이터 값 세트는 손상 데이터(damage data) 및/또는 파괴 데이터(failure data)에 해당할 수 있다. 이 데이터는 연성 물질의 손상 진화 능력(damage evolution capability)에 대한 정보일 수 있다. 손상은 물질 파괴로 이어지는 물질 강성의 점진적 저하일 수 있다. 손상 데이터 및/또는 파괴 데이터는 손상이 시작된 후 손상의 진화를 나타내기 위해 소성 변위 또는 물리적 에너지 소산과 같은 메시-독립적 척도(mesh-independent measures)를 기반으로 할 수 있다. 이 데이터는 동일한 물질에 동시에 작용하는 다양한 손상 메커니즘의 복합적 효과를 고려할 수 있으며, 각 메커니즘이 전체 물질 열화에 어떻게 기여하는지를 명시하는 옵션을 포함할 수 있다.
- [0049] 상기 입력 단계 전에, 본 방법은 상기 최적화 알고리즘을 위한 입력 데이터 값의 개수를 줄이는 특징화(featurization) 단계를 포함할 수 있다. 이러한 특징들의 정의 및 측정, 그 특징들이 서로 다른 실험적 충격 시험 결과에 존재하는지 여부와 그 특징들이 연산량을 줄이기 위한 (타겟) 출력 파라미터 값으로서 유용한지 여부에 따라 달라진다.
- [0050] 어느 경우이든, 실험적 데이터는 멀티-포인트 곡선이기 때문에, 가장 중요한 정보를 압축된 형태로 포함하는 더 작은 입력 데이터 값 세트로 이 정보를 줄이는 것이 유리하다. 이를 통해 더욱 간결한 인공 신경망 모델을 만들 수 있고, 모델 보정 속도를 높일 수 있고, 아티팩트(artifacts)를 제거할 수 있으며, 파라미터 가중치 정규화가 가능하게 된다.
- [0051] 바람직하게는, 하나 이상의 파라미터로서, 예를 들어 F_{max} 라는 참조부호로 표시되는 한계 하중(limit load)이 상기 입력 데이터 값에 해당한다. 한계 하중은 물질(구조물)이 안전하게 견딜 수 있는 최대 하중이다. 다시 말해, 구조물이 초기 소성 붕괴 상태에 도달할 때의 하중이다. 구조물에 가해지는 하중이 증가함에 따라, 변위는 하중이 항복 값에 도달할 때까지 탄성 구간에서 선형적으로 증가한다. 이 항복 값을 넘어서면, 하중-변위 응답이 비선형이 되고, 하중이 가해짐에 따라 변위의 소성 부분 또는 비가역적 부분이 꾸준히 증가한다. 소성 변형은 고체 전반으로 확산되고, 상기 한계 하중에서는 소성 영역이 매우 넓어지고 변위가 무한히 증가할 수 있는데, 이를 해당 부품이 붕괴되었다고 한다.
- [0052] 더욱 바람직하게는, 하나 이상의 파라미터로서 처짐(deflection)이 상기 입력 데이터 값에 해당하는데, 처짐은 예를 들어 U_{max} 라는 참조부호로 표시되며 상기 한계 하중에서의 처짐이다. 처짐은 구조 요소의 일부가 하중(예를 들어, 한계 하중)으로 인해 변형됨으로써 변위되는 정도이다. 이것은 각도 또는 거리로 나타낼 수 있다. 하중을 받는 부재의 처짐 거리는 해당 하중에서 상기 부재의 처짐 형상의 기울기를 수학적으로 나타내는 함수를 적분함으로써 연산될 수 있다. 더욱 바람직하게는, 처짐은 하나 이상의 실험적 힘-변위 신호의 센서 측정을 통해 직접 연산될 수 있다.

- [0053] 하나 이상의 파라미터로서 변형률 에너지(strain energy)가 상기 입력 데이터 값에 해당하는 것도 바람직한데, 이것은 특히 최대 하중(예를 들어, E_{br} 이라는 참조부호로 표시되는)으로부터 5% 감소까지의 힘-변위 신호 아래의 면적이다.
- [0054] 상술한 파라미터들은 상기 하나 이상의 기계적 시험이 계측 샤르피 충격 시험 또는 계측 천공 시험인 경우에 입력 데이터 값으로서 특히 바람직하다.
- [0055] 상기 하나 이상의 기계적 시험이 준정적(quasi-static) 인장 시험인 경우, 소정의 변형률 범위에서의 응력 곡선의 기울기(예를 들어, E 라는 참조부호로 표시됨)가 하나 이상의 파라미터로서 상기 입력 데이터 값에 해당할 수 있는데, 특히 0.05% 내지 0.25%의 변형률 구간에서 최소제곱 회귀(least squares regression)에 해당하는 기울기가 상기 입력 데이터 값에 해당할 수 있다.
- [0056] 후자의 경우, 항복 강도 역시 하나 이상의 파라미터로서 상기 입력 데이터 값에 해당할 수 있다. 항복 강도는 항복점에서의 응력(σ_y)을 나타내는 값으로, 바람직하게는 제로 오프셋 변형률에서의 초기 항복 응력이다. 상기 항복점은 응력-변형률 곡선에서 탄성 거동의 한계 및 소성 거동의 시작을 나타내는 지점이다. 항복점 아래에서는 물질이 탄성적으로 작용하며 가해진 응력이 제거되면 원래의 형태로 돌아간다. 그러나 항복점을 넘어가면 변형의 일부는 영구적이면서 비가역적이 되는데, 이를 소성 변형이라 한다.
- [0057] 출력 파라미터로서의 물성은 열-점탄성-점소성 모델로 나타낼 수 있다. 점소성은 물질의 속도-의존적 비탄성 특성을 나타낸다. 또한, 점탄성은, 변형될 때 점성 특성과 탄성 특성을 모두 나타내는 물질의 특성이다. 이 모델의 출력 파라미터는 온도에 의존적인 두 물성들 모두를 나타내기 때문에, 온도 및 변형률-속도에 의존적인 고유 물성을 나타내는 모델이 제공된다.
- [0058] 출력되는 상기 파라미터 값은 형상 의존적(응력/변형률 다축성의 특정 상태를 의미), 온도 의존적, 및 변형률-속도 의존적인 강성, 항복 응력, 및 파괴 변형률 중 하나 이상일 수 있다.
- [0059] 출력되는 상기 파라미터 값은 적어도 하나의 고유 물성을 포함할 수 있고, 출력되는 상기 파라미터 값은 상기 입력 데이터 값 세트를 벗어난 조건에서의 물성 예측에 적합한 특징을 나타낼 수 있다. 이러한 방식으로, 본 방법은 다양한 산업 분야(예를 들어, 환경 파라미터가 광범위하게 변할 수 있는 자동차 산업)에서 물성 예측을 위한 유용한 도구가 된다.
- [0060] 물질 모델은 바람직하게는 물질에 대한 구성 모델(constitutive model)이다. 물질에 대한 구성 모델은 탄성 또는 소성에 대한 비선형 모델을 기반으로 할 수 있으며, 바람직하게는 파괴 파라미터 보정이 있다(파괴 거동을 고려한다는 것을 의미).
- [0061] 물질에 대한 구성 모델은 탄성에 대한 비선형 모델을 기반으로 할 수 있다. 물질은 일반적으로 특정 하중까지만 탄성 거동을 갖는다. 그 후에는, 소성 변형이 된다. 물질은 비선형 탄성 응력-변형률 곡선을 가질 수 있는데, 이러한 경우에는 비선형 탄성 모델이 물질을 가장 잘 설명한다. 이러한 모델로는, 예를 들어, Blatz-Ko Rubber 모델, Mooney-Rivlin Rubber 모델, 및 점탄성 모델이 있다. 비탄성 영역에서는 물질마다 반응이 다르다.
- [0062] 추가적으로 또는 대안적으로, 물질의 구성 모델은 소성에 대한 비선형 모델을 기반으로 할 수 있다. 비탄성 변형이 발생하는 모델에서는, 복합 응력장(combined stress fields)에서 변형률의 수직 성분(normal component) 또는 전단 성분(shear component)이 증가함에 따라 응력의 수직 성분과 전단 성분이 모두 변한다.
- [0063] 상기 구성 모델은 Dassault Systemes Simulia, Inc.의 ABAQUS 2016 Analysis User's Guide, Part V: Materials에 기술된 하나 이상의 모델일 수 있다.
- [0064] 상기 구성 모델은 Livermore Software Technology Corporation의 LS-DYNA, KEYWORD USER'S MANUAL, VOLUME II-Material Models (2021)에 기술된 하나 이상의 모델일 수 있다.
- [0065] 상기 구성 모델은 다음의 모델들 중 하나 이상일 수 있다: Hooke 법칙에 기반한 선형 탄성 모델; 선형 점탄성 모델; 초탄성 모델(예를 들어, Arruda-Boyce, Ogden, Marlow, Mooney-Rivlin, Neo-Hookean, Polynomial); 선형 탄성 등방성 변형률 경화 소성 모델(등방성 및 이방성 항복을 각각 허용하는 관련 소성 유동을 갖는 Mises 또는 Hill 항복 표면); ABAQUS 모델[예를 들어, ABAQUS 완전 소성 모델, ABAQUS 등방성 경화 모델, ABAQUS 운동학적 경화 모델, ABAQUS 시험 데이터 직접 입력 모델(예를 들어, ABAQUS 시험 데이터 직접 입력 모델), ABAQUS 2층 점소성 모델, ABAQUS 항복 응력 비율 모델, ABAQUS 연성 금속의 점진적 손상 및 파괴 모델, 또는 ABAQUS 섬유-강화 물질의 점진적 손상 및 파괴 모델]; Johnson-Cook 등방성 경화 모델; Drucker-Prager 모델; Mohr-Coulomb

소성 모델; 크러셔블 폼(crushable foam) 소성 모델; Ramberg-Osgood 소성 모델; LS-DYNA MAT_24 모델; Johnson-Cook 속도 의존 모델; Bergstrom-Boyce 모델; Bergstrom Three Network 모델; Bergstrom Hybrid 모델; LS-DYNA SAMP-1 모델; 및/또는 LS-DYNA 모델[예를 들어, MAT_81, MAT_105, MAT_107 또는 MAT_120 등적 손상 모델(Lemaitre), 금속의 비-등적 손상 모델(Gurson), 플라스틱의 비-등적 손상 모델(SAMP), 균열 모델링].

[0066] 바람직한 실시예에서, 상기 하나 이상의 실험적 힘-변위 신호는 충격 하중 실험 동안 기록된 것이다.

[0067] 다른 측면에 따르면, 프로세서에 의해 실행될 수 있는 컴퓨터 프로그램 명령어들을 유형으로(tangibly) 저장하는 비일시적 컴퓨터 판독 가능 저장매체가 제공되는데, 상기 컴퓨터 프로그램 명령어들은 위에서 설명된 방법의 단계들을 정의한다.

도면의 간단한 설명

[0068] 본 발명의 실시예들은 예시적으로 도시된 것이며, 첨부 도면의 도면들에 의해 제한되지 않는데, 상기 도면들에서 동일한 참조번호는 유사한 구성요소들을 나타낸다.

도 1은 본 발명에 따른 컴퓨터로 구현되는 방법의 단계들을 보여주는 예시적 흐름도를 나타내고;

도 2는 본 발명에 따른 컴퓨터로 구현되는 방법의 단계들을 수행하는데 이용되는 인공 신경망의 예시적 구조를 보여주고;

도 3a는 본 발명에 따른 예시적 입력 데이터 세트를 보여주고;

도 3b는 본 발명에 따른 예시적 출력 파라미터 세트를 보여주고;

도 4는 예시적 최적화 기법을 보여주고;

도 5a 내지 도 5c는 폴리머 물질 A에 대한 -30°C 에서 50°C 까지의 서로 다른 온도에서의 실험적 IPT, INC 및 인장 곡선들을 각각 보여주고;

도 6a 내지 도 6c는 폴리머 물질 B에 대한 -30°C 에서 50°C 까지의 서로 다른 온도에서의 실험적 IPT, INC 및 인장 곡선들을 각각 보여주고;

도 7a 내지 도 7d는 물질 A의 물성들에 해당하는 출력 파라미터들을 그래프 형태로 보여주며;

도 8a 내지 도 8d는 물질 B의 물성들에 해당하는 출력 파라미터들을 그래프 형태로 보여준다.

발명을 실시하기 위한 구체적인 내용

[0069] 도 1은 본 발명에 따른 컴퓨터로 구현되는 방법(100)의 단계들을 보여주는 예시적 흐름도를 나타낸다. 상기 방법(100)의 선택적(optional) 단계들은 점선으로 표시되어 있다.

[0070] 상기 방법은 하나 이상의 물질의 적어도 탄소성 기계적 반응을 나타내는 파라미터 값을 출력하기 위한 것이다.

[0071] 단계 101은 입력 단계를 보여준다. 단계 101에는, 입력 단계가 도시되어 있다. 여기에서는, 기계적 충격 시험에서 도출된 하나 이상의 실험적 힘-변위 신호의 데이터 값 세트가 최적화 알고리즘로 입력되는데, 상기 최적화 알고리즘은 하나 이상의 신경 처리 유닛을 포함하는 학습된 인공 신경망(ANN)(200)(도 2 참조)을 더 포함한다.

[0072] 선택적 단계(도 1에는 도시되어 있지 않음)에서, 단계 101에서 입력된 여러 입력 데이터 값을 더욱 감소시키는 특징화 단계가 수행된다.

[0073] 단계 102는 최적화 알고리즘(최적화 기법)을 보여준다. 이 최적화 알고리즘에서는, 입력 파라미터(단계 101)와 인공 신경망(200)에 의해 수행되는 파라미터 값의 예측 간의 가능한 최소 차이(최적 적합)를 제공하는 파라미터 값 조합이 서치된다.

[0074] 단계 108은 출력 단계를 보여주는데, 여기에서는, 실험적 힘-변위 신호에 기초한 입력 데이터 값(101)과 단계 106의 추정된 파라미터 값 조합을 이용하여 ANN(200)에서 수행되어 도출된 이 신호들의 예측값 간의 사전 정의된 최소 차이를 발생시키는 파라미터 값 조합(302)이 상기 최적화 알고리즘(102)에 의해 출력된다. 복수의 실험적 신호들(예를 들어, INC, IPT, TEN 및 다양한 시험 온도)이 사용되는 경우, 최적화 루프는 각각의 입력 신호에 해당하는 특정 변형률-속도 및 온도에 각각 대응하는 최적의 파라미터 값 세트들(301)을 동시에 생성한다(도 4 참조). 이 세트들은 식 1 및 식 2에 의해 제한되고(constrained), 이에 따라 상기 최적화 알고리즘이 표 4에 나타난 파라미터 세트를 생성하게 된다. 따라서, 상기 최적화를 통해 온도-점탄성-점소성 물성이 결정될 수 있

다.

- [0075] 상기 최적화 알고리즘은 비교 단계(103)를 포함한다. 여기서는, 실험적으로 얻어진 상기 입력 데이터 값 세트(단계 101)가 상기 ANN(200)으로부터 도출되는 (힘-변위) 예측 신호와 비교된다. 처음에는, ANN(200)에 의한 이러한 예측 신호는 상기 파라미터(301)의 초기 추정값을 사용하여 생성된다.
- [0076] 상기 비교 단계(103)에 이어서 판단 단계(104)가 있는데, 여기서는, 상기 비교 결과(입력과 예측 간의 차이)를 하나 이상의 종료 기준[예를 들어, 최소 차이(최적 적합) 기준]과 비교한다. 단계 104에서 종료 기준/기준들이 충족되었다고 판단되면(yes-경우), 상기 최적화 알고리즘은 종료되고, 획득된 파라미터 값이 단계 108에서 출력된다.
- [0077] 단계 104에서 종료 기준/기준들이 충족되지 않았다고 판단되면(no-경우), 상기 최적화 알고리즘이 계속 진행된다. 그러면, 단계 106에서 ANN(200)이 상기 입력 값(301)에 대한 새로운 추정값을 얻고(이러한 추정값은 상기 최적화 알고리즘에 의해 자동으로 생성됨), 단계 107에서 이 입력 데이터 값(301)으로부터 그에 해당하는 힘-변위 신호를 예측한다. 이 단계 106은 최적화 알고리즘에 의해 수행되는 AI 모델의 “로컬 입력”이라고 할 수 있다. 이후, 상기 AI 모델은 단계 107에서 “로컬 출력”으로서 힘-변위 신호를 예측한다. 이 예측값은 유한 요소 시뮬레이션을 통해 사전 학습된 ANN(200)에 기반하여 생성된다. 단계 107의 출력(예측값)은 상기 비교 단계(103)로 다시 제공된다.
- [0078] 이 최적화 알고리즘은, 단계 104의 종료 기준이 충족되지 않는 한, 단계 107로부터의 예측값을 활용하여 출력 파라미터를 연산한다. 따라서, 상기 최적화 알고리즘은 최적화 루프이고, 바람직하게는 다목적 최적화 알고리즘이며, 더욱 바람직하게는 유전 다목적 최적화 알고리즘으로서, 기계적 충격 시험에서 도출된 하나 이상의 힘-변위 신호에 해당하는 입력 데이터 세트에 최적-적합한 물성 조합을 반복적으로 서치한다. 단계 103과 단계 104를 갖는 이 최적화 알고리즘(102)에서는, 입력된 데이터 값 세트(101)와 물질 모델의 파라미터 값의 추정값(301)을 이용하여 얻어지는 시뮬레이션 간에 최소 차이를 발생시키는(소위 “최적-적합”) 상기 물질 모델의 파라미터 값 조합이 상기 최적화 알고리즘을 통해 서치된다.
- [0079] 본 발명의 구현을 위해, 컴퓨터 프로그램 제품은 다음의 세 가지 핵심 요소를 포함할 수 있다: (1) 하나 이상의 신경 처리 유닛을 포함하고, 임의의 물질 파라미터 세트가 주어졌을 때 충격 시험의 주요 특성들을 예측하는 신경망 기반 모델(neural-network-based model)(NNM); (2) 상기 NNM에 의해 학습된 내용을 저장하는 신경망 파라미터 세트(neural-network parameter set)(NNS) - 상기 NNS는 유한 요소 시뮬레이션 등을 통해 다수의 연산을 수행함으로써 생성되는 데이터베이스를 이용하여 학습됨 -; 및 (3) 선택된 기준에 따라 주어진 실험에 최적으로 적합한 물질 파라미터 세트를 찾기 위해 상기 NNM을 사용하는 다중-최적화 최적화 기법(multi-optimization optimization scheme).
- [0080] 상기 최적화 루프(단계 102)를 위한 입력 데이터 값 세트는 물성을 결정해야 하는 실험 데이터에 기반한다.
- [0081] 이 특별한 발명의 기초 데이터로서 가장 적합한 실험 데이터는 예를 들어 -30°C 및 $+23^{\circ}\text{C}$ 의 두 개의 서로 다른 온도에서 준정적(quasi-static) 인장 시험(TEN)을 통해 얻어진다.
- [0082] 이 특별한 발명의 기초 데이터로서 가장 적합한 실험 데이터는 예를 들어 계측 충격 천공 시험(이하, 약칭하여 IPT)을 통해 얻어진다.
- [0083] 이 특별한 발명의 기초 데이터로서 가장 적합한 실험 데이터는 예를 들어 계측 샤르피 충격 시험(이하, 약칭하여 INC)을 통해 얻어진다. 이 샤르피 충격 시험은 원칙적으로 V-노치 샤르피 충격 시험 또는 비-노치 샤르피 충격 시험일 수 있다.
- [0084] 이 시험들(TEN, INC, IPT)은 힘-변위 신호(곡선) 형태의 수치 데이터를 생성한다. 본 방법(100)에 따르면, TEN, INC, IPT 시험들로부터 얻어지는 실험 결과에 최적-적합한 물성 조합을 보다 적은 연산량과 시간으로 찾을 수 있다.
- [0085] 실험 데이터가 멀티-포인트 힘-변위 신호(곡선)로 표현되므로, 가장 중요한 정보를 압축된 형태로 포함하는 더 작은 입력 값 세트로 단계 101의 입력 값 세트를 줄이는 것이 유리하다. 이를 통해 더욱 간결한 인공 지능 모델을 구현할 수 있고, 모델 보정 속도를 높일 수 있고, 아티팩트(artifacts)를 제거할 수 있으며, 파라미터 가중치 정규화가 가능하게 된다. 이러한 특징화 단계는 도메인 지식 및 전체 시험 시스템에 대한 이해를 필요로 한다.

[0086] 예시적으로, IPT 및 INC의 경우에 정의되는 특징들은 다음과 같다:

[0087] · 한계 하중($F_{\max}$)

[0088] · 처짐($U_{\max}$)($F_{\max}$ 에서)

[0089] · 최대 하중(E_{br})으로부터 5% 힘 강하까지의 힘-변위 신호 아래의 면적

[0090] 예시적으로, TEN의 경우에 정의되는 특징들은 다음과 같다:

[0091] · 0.05% 내지 0.25%의 변형률 구간에서 최소제곱 회귀에 해당하는 기울기(E)

[0092] · 항복 응력(σ_y)

[0093] 구성 물질 모델의 목적은 물질의 기계적 거동을 설명하기 위한 것이다. 도면들에 도시된 예에서는, 선형 탄성 등방성 변형률 경화 Mises 소성 모델이 사용되었는데, 이것의 입력 파라미터는 ABAQUS에서의 표 형식으로 입력될 수 있다. 상기 입력 파라미터는 ANN(200)에 대한 입력 데이터 세트(301)이다. 위에서 설명한 바와 같이, 물질의 기계적 거동을 설명하는 다른 구성 물질 모델들도 사용할 수 있다.

[0094] 도면들에 도시된 특정 물질 모델은 변형률-속도 의존적이 아닐 뿐만 아니라 온도 의존적이지도 않다. 그러나, 고려되는 세 가지 실험 데이터(TEN, INC, IPT) 각각에 상이한 변형률-속도가 적용되었고 실험 데이터를 제공하는 시험들 각각이 상이한 온도들에서 수행되었기 때문에, 변형률-속도 의존적 및/또는 온도 의존적 물질 모델이 필요하다.

[0095] 이 예에서, 탄성에 대한 비선형 모델

$$E(\theta) = A^E \left(1 + C^E \ln \left(\frac{\dot{\epsilon}_0^{dyn}}{\dot{\epsilon}_0^{qs}} \right) \right) (1 - T^{*m^E}) \quad (1)$$

[0096]

[0097] 및 소성에 대한 비선형 모델

$$Y(\bar{\epsilon}_p, \dot{\bar{\epsilon}}_p, \theta) = \left(A^Y + B^Y \bar{\epsilon}_p^{n^Y} \right) \left(1 + C^Y \ln \left(\frac{\dot{\bar{\epsilon}}_p}{\dot{\bar{\epsilon}}_0^{qs}} \right) \right) (1 - T^{*m^Y}) \quad (2)$$

[0098]

[0099] 은 참조번호 400에 도시된 최적화 루프에 구현된다.

[0100] 식 (1)은 변형률-속도 및 온도에 의존적인 탄성에 대한 추가 모델을 나타내는 반면, 식 (2)는 변형률-속도 및 온도에 의존적인 소성에 대한 추가 모델을 나타낸다.

[0101] 도면에 도시된 구현된 물질 모델은 온도 및 응력-삼축성(stress-triaxiality)에 의존하는 연성 손상 모델을 구현함으로써 파괴 파라미터의 보정을 가능하게도 한다:

$$\bar{\epsilon}_p^D(\eta, \theta) = \begin{cases} \frac{L^{tri}}{1 + e^{-k^{tri}(\theta - \theta_t^{tri})}} & \eta = 1.00 \\ \frac{L^{bi}}{1 + e^{-k^{bi}(\theta - \theta_t^{bi})}} & \eta = 0.66 \\ \bar{\epsilon}_p^D(0.66, \theta) * R & \eta = 0.33 \\ 0.35 & \eta = 0.00 \\ 100 & \eta = -0.33 \end{cases} \quad (3)$$

[0102]

[0103] 여기서, $\bar{\epsilon}_p^D$ 는 연성 손상 시작 시점의 등가 소성 변형률이다. 도면으로 도시된 상기 구현된 물질 모델의 완전한 정의는 총5개의 온도-의존적 및 변형률-속도-의존적 파라미터들과 6개의 파괴 파라미터들이 결정되어야 한다(아래의 표 1참조).

표 1 - 온도 및 변형률-속도 의존적 파라미터 & 파괴 파라미터

파라미터	단위	설명	경계
ρ	$\frac{\text{ton}}{\text{mm}^3}$	밀도	$9e^{-10}$
ν	—	푸아송 비	0.40
ϵ_0^{gs}	s^{-1}	준정적 속도	0.01
ϵ_0^{dyn}	s^{-1}	동적 속도	254
θ_0	$^{\circ}C$	기준 온도	-30
θ_m	$^{\circ}C$	용융 온도	[140, 180]
A^E	MPa	기준 강성	2840
C^E	—	변형률 속도 계수	[0.02, 0.10]
m^E	—	온도 지수	[0.20, 0.80]
A^Y	MPa	기준 항복 강도	42
B^Y	—	변형률 경화 계수	5
C^Y	—	변형률 속도 계수	[0.02, 0.06]
m^Y	—	온도 지수	[0.20, 0.60]
n^Y	—	변형률 경화 지수	1
L^{tri}	—	파괴 시 최대 소성 변형률	[0.50, 0.75]
k^{tri}	$^{\circ}C^{-1}$	로지스틱 성장률	[0.05, 0.18]
θ_t^{tri}	$^{\circ}C$	연성-취성-전이	[30, 50]
L^{bi}	—	파괴 시 최대 소성 변형률	[1.20, 3.50]
k^{bi}	$^{\circ}C^{-1}$	로지스틱 성장률	[0.05, 0.18]
θ_t^{bi}	$^{\circ}C$	연성-취성-전이	[-20, 0]
R	—	단축 대 이축 비율	0.85
$\bar{u}_p^f$	—	파괴 시 변위	0.01

[0104]

[0105]

표 1의 “경계(boundaries)” 열은 각 개별 파라미터의 경계를 나타낸다. 이 열에 단일 값만이 기재된 파라미터는 고정된 값이고, 따라서 해당 파라미터에 대해서는 경계가 설정될 필요가 없다.

[0106]

위에서 언급한 바와 같이, 연산된 FE 시뮬레이션은 ANN(200)을 학습시키기 위한 데이터베이스를 생성하는데 사용된다. 이후, 상기 ANN(200)은 상기 매핑 단계(107)에서 훨씬 더 빠른 응답을 제공함으로써 이러한 FE 시뮬레이션을 대체(대리)한다.

[0107]

위에서 언급한 바와 같이, FE 시뮬레이션은 탄소성 응답만을 고려하는 반면, 변형률-속도 의존성과 온도 의존성 그리고 파괴 파라미터 보정은 예를 들어 최적화 단계(104)에서 식 (1) 내지 식 (3)을 통해 고려된다. INC에 대한 총36,878회의 시뮬레이션과 IPT에 대한 총22,755회의 시뮬레이션이 각각 실시되었다. 각각의 시뮬레이션은 다음의 표 2에 나타난 값을 기반으로 서로 다른 파라미터 조합을 사용하였다.

표 2 - 매핑 단계(103) 동안 사용되는 FE 시뮬레이션 데이터베이스 생성에 사용되는 탄소성 물질 파라미터

파라미터	단위	데이터베이스 값
E	MPa	[250, 500, ... 4000, 4500]
$Y(\bar{\epsilon}_p = 0)$	MPa	[15, 20, 25, ... 50, 55, 60]
$Y(\bar{\epsilon}_p = 1)$	MPa	[5] + $Y(\bar{\epsilon}_p = 0)$
$Y(\bar{\epsilon}_p = 2)$	MPa	[-10, 5, 40] + $Y(\bar{\epsilon}_p = 1)$ + $Y(\bar{\epsilon}_p = 0)$
$\bar{\epsilon}_p^D(\eta = 0.33)$	-	[0.05, 0.1, 0.25, ... 2.5, 3.0, 3.5]
$\bar{\epsilon}_p^D(\eta = 0.66)$	-	[0.05, 0.1, 0.25, ... 2.5, 3.0, 3.5]
$\bar{\epsilon}_p^D(\eta = 1.00)$	-	[0.05, 0.1, 0.25, ... 2.5, 3.0, 3.5]
$\bar{u}_p^f$	mm	[0, 0.05, 0.1]

[0108]

[0109]

도 2는 상기 방법(100)에서 사용되는, 특히 도 1에 도시된 매핑 단계(103)를 위해 사용되는, 인공 신경망(200)의 예시적 구조를 나타낸다.

[0110]

인공 신경망(ANN)은, 상기 ANN(200)으로 입력되는 입력 값 세트를 처리하기 위하여 그리고 상기 ANN(200)으로부터의 출력 파라미터(302)를 생성하기 위하여, 뉴런(201, 202, 203)으로 이루어진 네트워크를 사용한다. 예를 들어, 상기 ANN(200)의 각 뉴런(201, 202, 203)은 도 1의 단계 102에서 입력 데이터 세트(301)를 수신한다. 뉴런으로 입력되는 입력 데이터 값(301)의 일부는 상기 ANN(200)의 다른 뉴런의 출력일 수 있다. 뉴런으로의 입력 중 일부는 상기 ANN(200)으로 제공되는 입력일 수 있다. 상기 ANN(200)에서 뉴런(201, 202, 203) 간의 입력/출력 관계는 상기 ANN(200)의 뉴런 연결성을 나타낸다.

[0111]

예를 들어, 각각의 뉴런(201, 202, 203)은 그 입력을 위한 바이어스, 활성화 함수, 및 시냅스 가중치 세트(20

4)를 각각 가질 수 있다. 활성화 함수는 계단 함수, 선형 함수, 로그-시그모이드 함수 등의 형태일 수 있다. 상기 ANN(200)에서 서로 다른 뉴런(201, 202, 203)은 서로 다른 활성화 함수를 가질 수 있다.

[0112] 예를 들어, 각각의 뉴런(201, 202, 203)은 입력과 바이어스의 가중 합(weighted sum)을 생성한 후 상기 가중 합의 함수인 출력값을 생성할 수 있는데, 상기 가중 합의 함수는 상기 뉴런(201, 202, 203)의 활성화 함수를 사용하여 연산된다.

[0113] 일반적으로, 상기 ANN(200)의 입력값(들)과 출력값(들) 간의 관계는, 상기 ANN(200)에서 상기 뉴런(201, 202, 203)의 연결성을 나타내는 데이터는 물론이고 각 뉴런(201, 202, 203)의 바이어스, 활성화 함수, 및 시냅스 가중치를 포함하는 ANN 모델에 의해 정의된다. 주어진 모델을 기반으로, 컴퓨팅 장치는 ANN(200)으로 입력되는 특정 입력값 세트로부터 상기 ANN(200)의 출력값(들)을 연산하도록 구성될 수 있다.

[0114] 일반적으로, ANN(200)은 지도 방식(supervised method)으로 사용하여 학습될 수 있으며, 이 경우 상기 ANN(200)에서의 파라미터는 각각의 입력값과 결부된 또는 이로부터 발생된 알려진 출력값과 상기 입력값을 상기 ANN(200)에 적용하여 생성되는 연산된 출력값 사이의 오차를 최소화하거나 줄이도록 조정된다. 지도 러닝/학습 방식의 예로는 강화 학습 및 오류 보정을 통한 학습이 있다.

[0115] 대안적으로 또는 조합으로, ANN(200)은 비-지도 방식을 이용하여 학습될 수 있는데, 이 경우에는 주어진 입력값 세트로부터 발생하는 정확한 출력값을 학습이 완료되기 전에는 알 수 없다. ANN(200)은 항목을 다수의 카테고리로 분류하거나 데이터 포인트를 클러스터로 분류하도록 학습될 수 있다.

[0116] 정교한 머신 러닝/학습 패러다임을 위해 다중 학습 알고리즘이 채용될 수 있다.

[0117] 딥 러닝은 입력 데이터로부터 점진적으로 특징을 추출하기 위해 다중 계층의 머신 러닝을 사용한다. 예를 들어, 하위 계층은 이미지에서 에지(edges)를 식별하도록 구성될 수 있고; 상위 계층은 상기 하위 계층을 이용하여 감지된 에지를 기초로 얼굴, 물체, 이벤트 등 이미지에 담긴 항목을 식별하도록 구성될 수 있다. 딥 러닝은 심층 신경망, 심층 신뢰 신경망, 순환 신경망, 및/또는 합성곱 신경망과 같은 ANN(200)을 통해 구현될 수 있다.

[0118] 여기에 개시된 적어도 일부 실시예들은 ANN(200)의 연산을 수행하도록 구성된 범용 집적 회로 장치를 제공한다. 집적 회로 장치는 딥 러닝 가속기(DLA), 랜덤 액세스 메모리(RAM), 및/또는 직접 매체 액세스(DMA) 컨트롤러를 포함할 수 있다. 직접 회로 장치는 RAM에 대한 동시 액세스를 위해 별도의 연결로 구성될 수 있다.

[0119] DLA는 벡터 및/또는 행렬의 곱셈 및 누산을 포함하되 이에 한정되지 않는 병렬 벡터 및/또는 행렬 연산을 수행하도록 특화 및/또는 최적화된 범용의 프로그래밍 가능한 하드웨어 연산 로직 세트를 포함할 수 있다. 또한, DLA는 정수 이진수에 대한 산술 및 비트 연산을 수행하는 하나 이상의 산술-논리 유닛(ALU)을 포함할 수 있다.

[0120] DLA는 ANN(200)의 연산을 수행하도록 명령어 세트를 통해 프로그래밍될 수 있다.

[0121] 벡터 및 행렬을 처리하는 DLA의 세분성(granularity)은 DLA가 하나의 명령어를 실행하는 동안 처리될 수 있는 벡터/행렬의 최대 단위에 해당한다. 벡터/행렬 피연산자에 대해 사전에 정의된 연산을 수행하는 명령어가 실행되는 동안, 벡터/행렬 피연산자의 요소들이 DLA에 의해 병렬로 처리됨으로써 메모리/데이터 액세스와 관련된 에너지 소비 및 실행 시간을 줄일 수 있다. DLA의 세분성 단위로 벡터/행렬 피연산자에 대해 수행되는 연산은 더 큰 크기의 벡터/행렬에 대한 연산을 구현하기 위한 빌딩 블록으로 사용될 수 있다.

[0122] 일반적/실용적 ANN(200)의 구현에는 DLA의 연산 세분성보다 큰 크기의 벡터/행렬 피연산자가 관여된다. DLA를 사용하여 이러한 ANN(200)을 구현하기 위해서는, 큰 크기의 벡터/행렬 피연산자가 포함된 연산을 DLA의 세분성의 벡터/행렬 피연산자 연산들로 분할할 수 있다. DLA는 큰 벡터/행렬 피연산자가 포함된 연산을 수행하도록 명령어를 통해 프로그래밍될 수 있다. 예를 들어, 명령어에 따라 DLA의 세분성의 벡터 및 행렬을 처리하는 DLA의 원자적 연산 기능을 프로그래밍함으로써 ANN(200)에서의 연산을 구현할 수 있다.

[0123] 일반적인 ANN(200)은 표준 형식[예를 들어, 개방형 신경망 교환(ONNX)]으로 설명/명시될 수 있다. ANN(200)의 설명을 ANN(200)의 연산 수행을 위한 DLA용 명령어로 변환하기 위하여 컴파일러가 사용될 수 있다. ANN(200)을 구현함에 있어서의 DLA 성능을 향상시키기 위해 컴파일러는 명령어 세트를 최적화할 수 있다.

[0124] 예를 들어, ANN(200)으로의 입력 데이터 스트림(301)은 일련의 입력 데이터 세트 형태로 구성될 수 있다. 각각의 입력 데이터 세트는 일정 시간 슬롯 동안 ANN에 입력될 입력 세트를 위한 것이다. DLA가 현재 입력 세트로부터 출력을 연산하는 동안, DMA 컨트롤러는 다음 입력 세트를 RAM에 저장할 수 있고; 그와 동시에 CPU는 이전 입력 세트에 대해 생성된 출력을 RAM으로부터 가져올 수 있다. 따라서, ANN(200)으로 입력되는 입력 데이터의 준

비 및 처리 작업이 CPU로부터 오프로드(offload)될 수 있다. DLA, RAM 및 DMA 컨트롤러의 조합은 ANN(200)의 결과를 CPU로 독립적으로 제공하는 독립적 공급자 역할을 할 수 있다. CPU는 필요할 때마다 출력 세트를 가져올 수 있다. CPU는 ANN(200)으로부터의 출력이 필요하지 않으면 ANN으로 입력을 공급하는 작업을 일시 중지하도록 DMA 컨트롤러에 지시할 수 있다. 이후, ANN(200)으로부터의 출력이 필요하게 되면, CPU는 입력 데이터를 RAM으로 로딩하는 작업을 재개하도록 DMA 컨트롤러에 지시할 수 있다.

[0125] 도 1의 매핑 단계(107)를 수행하기 위해 도 2에 도시된 ANN(200)을 위한 IPT 및 INC 시험을 모델링하기 위해, 피드 포워드 멀티-레이어-펄셋론 신경망 모델이 구현될 수 있으며, 여기서는 Scikit-Learn Python 라이브러리를 사용하는 것이 바람직하다. 각각의 시험(IPT, INC)은 그 자체의 하이퍼파라미터를 가진 그 자체의 ANN 모델을 생성한다.

[0126] 표 2에 정의된 물질 파라미터가 도 2에 도시된 네트워크 입력 뉴런(201)에 입력된다. IPT 및 INC에 기반한 물성 예측을 위한 바람직한 입력 데이터 세트가 도 3a에 나열되어 있다.

[0127] 네트워크는 뉴런(203)을 통해 TEN, IPT, INC에 대해 위에서 나열된 특징들을 출력 파라미터(302)로서 다음과 같이 출력(예측)한다:

[0128] IPT 및 INC 시험의 경우, 출력 파라미터(302)는 다음과 같다(도 3b도 참조):

[0129] · 한계 하중(F_{max})

[0130] · 처짐(U_{max})(F_{max} 에서)

[0131] · 최대 하중(E_{br})으로부터 5% 힘 강하까지의 힘-변위 신호 아래의 면적

[0132] 도 2에 도시된 ANN(200)은 N(1)개 및 N(2)개 뉴런들(202)을 갖는 두 개의 은닉 계층들을 갖는다. 각 계층에는 비선형성 도입을 위한 정류 선형 유닛 활성화가 사용될 수 있다.

[0133] INC 및 IPT에 대한 ANN(200) 학습을 위해 직접 그리드 서치 방식(direct grid search approach)과 같은 최적화 알고리즘을 채용하여 다음의 표 3에 나열된 모델 하이퍼파라미터를 결정할 수 있다.

표 3 - AI 모델 하이퍼파라미터

	min	max	Δ	INC	IPT
$N^{(1)}$	100	500	100	300	300
$N^{(2)}$	100	500	100	400	300
$\log \alpha$	-6	-2	1	-5	-5
b	200	1000	200	200	400

[0134]

[0135] 물질 모델을 보정[입력 데이터(301)의 실험 결과에 최적 적합하는 물성을 결정하는 것을 의미]하기 위해, 도 1에 도시된 바와 같이 그리고 도 4에 더욱 자세히 도시된 바와 같이, 다목적 최적화 알고리즘이 적용된다.

[0136] 이와 같은 방식으로, 알고리즘이 최적의 솔루션[= 입력 단계(102)에서 입력되는 데이터 값 세트(301)와 이 파라미터 값 조합(302)으로 수행된 유한 요소 시뮬레이션 간의 사전 정의된 최소 차이]을 찾을 때, 모든 온도에서 모든 기계적 충격 시험들(예를 들어, INC, IPT, 인장 시험)에 대해 동시에 최적의 솔루션을 찾아야 하고, 그와 동시에, 식(1) 내지 식(3)으로 설명된 변형률-속도 및 온도 의존성에 의해 부과되는 추가 제약 조건도 만족해야 한다.

[0137] 도 4에는, 대표적인 변형률-속도 및 온도의 그리드에서 임의의 개수의 실험, 즉 기계적 충격 시험(예를 들어, INC, IPT, TEN)을 수행할 수 있게 해주는 프레임워크(framework)가 도시되어 있다. 식(1), 식(2) 및 식(3)에 의해 정의되는 구성 출력 파라미터(302)의 조합을 구할 수 있다. 상기 기법 전체를 통해 물성 표가 생성된다(표 4 참조):

표 4 - 본 발명을 통해 결정된 물성들

θ_m	C^E	m^E	C^Y	m^Y	
152	0.07	0.30	0.051	0.54	
k^{bi}	θ_t^{bi}	L^{bi}	k^{tri}	θ_t^{tri}	L^{tri}
0.077	-16	3.48	0.09	30	0.78

표 4의 이 물성들은 서로 다른 온도 및 변형률-속도에 대해 보정된다. 표 4에 따른 출력 파라미터의 컬렉션은 열-점탄성-점소성 모델 파라미터이다.

ANN(200)을 이용한 최적화(400)에서의 완전한 파라미터 결정 기법이 도 4에 도시되어 있다. 피드백 루프는 탄성 및 소성에 대한 파라미터를 ANN(200)으로 제공하고, 상기 ANN(200)의 출력 값은 목적/적합도 유닛(objective/fitness unit)(401)과 비교된다.

ANN(200)의 일반화 성능이 표 5에 나와 있다. 이것은 결정 계수(R2)와 평균 절대 오차(MAE)를 통해 정량화된다.

표 5 - ANN(200)의 일반화 성능

	$IPT R2$	$IPT MAE$	$INC R2$	$INC MAE$
f_{max} / N	0.997	21.29	0.988	3.91
u_{max} / mm	0.970	0.22	0.976	0.12
E_{br} / J	0.996	0.28	0.992	0.017

최적화 기법(400)을 실행하기 위해, 여섯 개의 실험들, 즉 23℃에서의 IPT 실험, -30℃에서의 IPT 실험, 23℃에서의 INC 실험, -30℃에서의 INC 실험, -30℃에서의 TEN 실험, 및 30℃에서의 TEN 실험이 보정에 사용되었다. 0℃, 30℃ 및 50℃에서의 나머지 IPT 및 INC 실험들은 ANN(200)이 얼마나 정확하게 이 실험 곡선들을 예측하는지 평가하기 위한 검증에만 사용되었다. 상기 최적화 기법(400)은 100개의 세대들(generations)로 실행되도록 구성되었는데, 각각의 세대는 표 1의 경계 내의 세트에 해당하는 200개의 개체들로 구성되었다.

도 5a 내지 도 5c는 폴리머 물질 A에 대해 두 개의 다른 온도에서 수행된 실험적 IPT, INC 및 인장 곡선들을 각각 보여준다. 물질 A는 59.7 wt.-%의 소비자 사용 후 재활용 폴리프로필렌(Borealis AG에서 시판, ISO 1183에 따른 밀도는 915 kg/m³, ISO 1133에 따른 230℃에서의 MFR₂는 20.0 g/10min) + 40 wt.-%의 HEC01(Borealis AG에 의해 시판되는 헤테로상 폴리프로필렌, ISO 1133에 따른 230℃에서의 MFR₂는 11.0 g/10min, 고유 점도는 2.1 dl/g) + 0.3 wt.-%의 Irganox B225(항산화제, BASF에 의해 시판)로 구성된 조성물이다. 이하에서 물질 A를 언급할 때는, 이 조성물을 의미한다.

도 6a 내지 도 6c는 폴리머 물질 B에 대해 두 개의 다른 온도에서 수행된 실험적 IPT, INC 및 인장 곡선들을 각각 보여준다. 물질 B는 79.7 wt.-%의 소비자 사용 후 재활용 폴리블렌드 PE/PP(Borealis AG에서 시판, ISO 1183에 따른 밀도는 940 kg/m³, ISO 1133에 따른 230℃에서의 MFR₂는 5.5 g/10min) + 20 wt.-%의 Queo8201(에틸렌계 1-옥텐 플라스톰, Borealis AG에 의해 시판, ISO 1183에 따른 밀도는 883 kg/m³, ISO 1133에 따른 190℃에서의 MFR₂는 1.1 g/10min) + 0.3 wt.-%의 Irganox B225(항산화제, BASF에 의해 시판)로 구성된 조성물이다. 이하에서 물질 B를 언급할 때는, 이 조성물을 의미한다.

물질 A 및 물질 B에 대한 각각의 -30℃부터 50℃까지의 다양한 온도에서의 실험적 IPT 곡선이 도 5a 및 도 6a에 각각 나타나 있다.

물질 A 및 물질 B에 대한 각각의 -30℃부터 50℃까지의 다양한 온도에서의 실험적 INC 곡선이 도 5b 및 도 6b에 각각 나타나 있다.

물질 A 및 물질 B에 대한 각각의 -30℃ 및 23℃의 온도에서의 실험적 인장 곡선이 도 5c 및 도 6c에 각각 나타나 있다.

도 5a-5c 및 도 6a-6c에 따른 -30℃부터 50℃까지의 다양한 온도에서의 IPT, INC 및 TEN 곡선들은 각각 입력 데이터 값 세트에 제공된다. 위에서 설명한 바와 같이, 이 입력 데이터 값 세트를 기초로 광범위한 온도 및 변형률-속도에서의 물성들이 추출될 수 있다. 여기서, "물성"이란 용어는 물질의 열-점탄성-점소성 및 파괴 응답을

정의하는 표 4의 구성 출력 파라미터 세트에 이해되어야 한다.

- [0150] 도 5a-5b 및 도 6a-6b는 물질 A와 물질 B에 대한 IPT 및 INC 충격 시험들에서의 실험적 힘-변위 신호들을 각각 보여준다. 점 기호($\cdot$)의 x 좌표 및 y 좌표는 입력 데이터 세트(301)로서 입력된 실험적 한계 하중($F_{\max}$) 및 실험적 처짐($U_{\max}$) 특징들에 각각 해당한다. x-기호(x)의 x 좌표 및 y 좌표는 출력 값(302)으로서 도출된 예측 한계 하중($F_{\max}$) 및 예측 처짐($U_{\max}$) 특징들에 각각 해당한다.
- [0151] 도 5a-5b 및 도 6a-6b의 각 차트 하단에 있는 수치는 최대 하중(E_{br}) 특징의 힘 강하 크기를 나타내고, 보정된 값이 별표(*)로 표시되어 있다. 이 예에서는 실험 특징들의 위치 및 크기와 예측 특징들의 위치 및 크기를 비교함으로써 본 발명의 적합도 및 외삽 성능을 평가할 수 있다. -30°C 와 $+23^{\circ}\text{C}$ 의 실험 곡선들의 경우, 결과는 적합(최소 차이를 가지므로 최적 적합)이다. 그러나, 다른 모든 곡선들(0°C , $+30^{\circ}\text{C}$ 및 $+50^{\circ}\text{C}$ - 회색 배경으로 표시된)의 경우에는, 해당 실험 곡선이 구성 출력 파라미터를 추출하는데 사용되지 않았으므로 결과는 실제로 예측이다.
- [0152] 도 7a 내지 도 7d는 물질 A의 물성을 그래프 형태로 나타낸 출력 파라미터를 보여준다. 도 8a 내지 도 8d는 물질 B의 물성을 그래프 형태로 나타낸 출력 파라미터를 보여준다. 이 정보는, 일반적으로 유한 요소 방법을 통한 시뮬레이션을 사용하여 부품 및 구성요소를 설계할 때 물질 A와 물질 B의 열-점탄성-점소성 응답과 파괴 응답을 나타내는데 직접 사용될 수 있다.
- [0153] 도 7a는 물질 A의 영률(탄성률)(MPa)을 온도($^{\circ}\text{C}$)와 변형률 속도(1/s)에 따른 함수로 나타낸 것이다. 도 7b는 물질 A의 항복 시작(항복 응력)(MPa)을 온도($^{\circ}\text{C}$)와 변형률 속도(1/s)에 따른 함수로 나타낸 것이다. 도 7c는 물질 A의 항복 경화(경화 파라미터)(MPa)를 소성 등가 변형률에 따른 함수로 나타낸 것이다. 도 7d는 물질 A의 손상 시작 변형률(파괴 변형률)을 온도($^{\circ}\text{C}$)와 응력/변형률 다축성(multiaxiality) 상태에 따른 함수로 나타낸 것이다.
- [0154] 도 8a는 물질 B의 영률(탄성률)(MPa)을 온도($^{\circ}\text{C}$)와 변형률 속도(1/s)에 따른 함수로 나타낸 것이다. 도 8b는 물질 B의 항복 시작(항복 응력)(MPa)을 온도($^{\circ}\text{C}$)와 변형률 속도(1/s)에 따른 함수로 나타낸 것이다. 도 8c는 물질 B의 항복 경화(경화 파라미터)(MPa)를 소성 등가 변형률에 따른 함수로 나타낸 것이다. 도 8d는 물질 B의 손상 시작 변형률(파괴 변형률)을 온도($^{\circ}\text{C}$)와 응력/변형률 다축성 상태에 따른 함수로 나타낸 것이다.
- [0155] 본 개시는 위에서 설명된 방법을 수행하는 방법 및 장치를 포함하며, 이러한 방법을 수행하는 데이터 처리 시스템, 및 데이터 처리 시스템에 의해 수행될 때 상기 시스템이 이러한 방법을 수행하도록 하는 명령어들을 포함하는 컴퓨터 판독 가능 매체를 포함한다.
- [0156] 비휘발성 메모리는 데이터 처리 시스템의 나머지 구성요소들과 직접 연결되는 로컬 디바이스일 수 있다. 모델 또는 인터넷 인터페이스와 같은 네트워크 인터페이스를 통해 상기 데이터 처리 시스템에 연결되는 네트워크 저장 장치처럼 상기 시스템과 원격으로 연결되는 비휘발성 메모리도 사용될 수 있다.
- [0157] 본 명세서에서는, 설명의 단순화를 위해, 일부 기능들 및 동작들이 소프트웨어 코드에 의해 수행 또는 유발되는 것으로 설명된다. 그러나, 이러한 표현은 해당 기능들이 마이크로프로세서와 같은 프로세서에 의한 코드/명령어 실행의 결과임을 명시하는데도 사용된다.
- [0158] 대안적으로 또는 조합으로, 여기에서 설명되는 기능들 및 동작들은 소프트웨어 명령어의 사용 여부와 관계없이 특수 목적 회로를 이용하여 구현될 수 있는데, 예를 들어 주문형 반도체(ASIC) 또는 필드-프로그램머블 게이트 어레이(FPGA)를 이용하여 구현될 수 있다. 실시예들은, 소프트웨어 명령어 없이 또는 소프트웨어 명령어와의 조합으로, 하드웨어에 내장된 회로를 이용하여 구현될 수 있다. 따라서, 본 기술은 하드웨어 회로와 소프트웨어의 특정 조합으로 국한되지 않을 뿐만 아니라 데이터 처리 시스템에 의해 실행되는 명령어들에 대한 특정 소스로 국한되지 않는다.
- [0159] 어느 한 실시예는 완전한 기능을 갖춘 컴퓨터 및 컴퓨터 시스템에서 구현될 수 있는 반면, 다양한 다른 실시예들은 다양한 형태의 컴퓨팅 제품으로 배포될 수 있으며, 배포를 실제로 수행하는데 사용되는 기계의 종류나 컴퓨터 판독 가능 매체의 종류와 무관하게 적용될 수 있다.
- [0160] 개시된 적어도 일부 관점들은 적어도 부분적으로 소프트웨어로 구현될 수 있다. 즉, 상기 기술은 컴퓨터 시스템 또는 그 밖의 데이터 처리 시스템에서 마이크로프로세서와 같은 그 프로세서에 응답하여 수행될 수 있는데, 상기 프로세서는 ROM, 휘발성 RAM, 비휘발성 메모리, 캐시 또는 원격 저장 장치와 같은 메모리에 들어 있는 일련

의 명령어들을 실행한다.

- [0161] 실시예들을 구현하기 위해 실행되는 루틴은 운영체제 또는 특정 어플리케이션, 컴포넌트, 프로그램, 객체, 모듈 또는 “컴퓨터 프로그램”이라 불리는 일련의 명령어들의 일부로 구현될 수 있다. 컴퓨터 프로그램은 일반적으로 컴퓨터의 다양한 메모리 및 저장 장치에 여러 시점에 설정된 하나 이상의 명령어 집합을 포함하며, 상기 명령어 집합이 컴퓨터의 하나 이상의 프로세서에 의해 읽혀져 실행되면 상기 컴퓨터가 상기 다양한 관점들과 관련된 된 요소들을 실행하는데 필요한 작업들을 수행하게 된다.
- [0162] 기계 판독 가능 매체는 소프트웨어 및 데이터를 저장하는데 사용될 수 있는데, 이러한 소프트웨어 및 데이터는 데이터 처리 시스템에 의해 실행될 때 상기 시스템이 다양한 방법들을 수행하도록 한다. 상기 실행 가능한 소프트웨어 및 데이터는 예를 들어 ROM, 휘발성 RAM, 비휘발성 메모리 및/또는 캐시를 포함한 다양한 장소에 저장될 수 있다. 이 소프트웨어 및/또는 데이터의 일부가 이러한 저장 장치들 중 어느 하나에 저장될 수 있다. 또한, 데이터와 명령어들은 중앙 집중식 서버 또는 P2P 네트워크로부터 얻을 수 있다. 데이터와 명령어들의 서로 다른 부분들이 서로 다른 또는 동일한 통신 세션에서 서로 다른 시간에 서로 다른 중앙 집중식 서버 및/또는 P2P 네트워크로부터 얻어질 수 있다. 데이터와 명령어들은 어플리케이션 실행 전에 그 전체가 얻어질 수 있다. 대안적으로, 데이터와 명령어들의 일부는, 실행을 위해 필요할 때에는, 동적으로 적시에 얻어질 수 있다. 따라서, 데이터와 명령어들은 특정 시점에 그 전체가 기계 판독 가능한 매체에 존재할 필요는 없다.
- [0163] 컴퓨터 판독 가능 매체의 예에는 무엇보다도 휘발성 및 비휘발성 메모리 장치, ROM, RAM, 플래시 메모리 장치, 플로피 디스크 및 그 밖의 이동식 디스크, 자기 디스크 저장 매체, 광학 저장 매체(예를 들어, CD ROM, DVD 등)와 같은 비일시적, 기록 가능, 및 기록 불가능 타입의 매체가 포함되지만, 이들로 국한되는 것은 아니다. 컴퓨터 판독 가능 매체는 상기 명령어들을 저장할 수 있다.
- [0164] 상기 명령어들은 전기, 광학, 음향, 또는 그 밖의 형태의 전파 신호들(예를 들면, 반송파, 적외선 신호, 디지털 신호 등)을 위한 디지털 및 아날로그 통신 링크들에도 구현될 수 있다. 다만, 반송파, 적외선 신호, 디지털 신호 등과 같은 전파 신호들은 유형의 기계 판독 가능 매체가 아니며 명령어들을 저장할 수 없다.
- [0165] 일반적으로, 기계 판독 가능 매체는 기계(예를 들어, 컴퓨터, 네트워크 장치, PDA, 제조 장비, 하나 이상의 프로세서의 세트를 갖춘 임의의 장치 등)가 액세스할 수 있는 형태로 정보를 제공하는(즉, 저장 및/또는 전송하는) 모든 메커니즘을 포함한다.
- [0166] 다양한 실시예들에서, 상기 기술의 구현을 위해 하드웨어에 내장된 회로가 소프트웨어 명령어들과 함께 사용될 수 있다. 따라서, 상기 기술은 하드웨어 회로와 소프트웨어의 특정 조합으로 한정되지 않을 뿐만 아니라 데이터 처리 시스템에 의해 실행되는 명령어들의 소스에 의해서도 제한되지 않는다.
- [0167] 상기 설명 및 도면은 예시적인 것이며 제한적인 것으로 해석되어서는 안 된다. 심도 있는 이해를 제공하기 위해 다수의 구체적인 세부 사항들이 설명되어 있다. 그러나, 경우에 따라, 설명의 모호함을 피하기 위해, 잘 알려져 있거나 통상적인 세부 사항은 기재되어 있지 않다. 본 개시 내용에서 하나 또는 일 실시예에 대한 참조는 반드시 동일한 실시예를 지칭하는 것은 아니며, 그러한 참조는 적어도 하나를 의미한다.
- [0168] 상기 명세서에서, 본 개시 내용은 그 특정 예시적 실시예들을 참조하여 설명되었다. 다음의 청구항들에 기재된 더 넓은 범위를 벗어나지 않으면서 이들에 대한 다양한 수정이 이루어질 수 있음은 명백할 것이다. 따라서, 본 명세서 및 도면은 제한적인 의미보다는 예시적인 의미로 간주되어야 한다.


부호의 설명

- [0169] 100 방법
- 101-109 방법 단계들
- 200 인공 신경망(ANN)
- 201 ANN의 입력 뉴런
- 202 ANN의 중간(은닉) 뉴런
- 203 ANN의 출력 뉴런
- 301 입력 데이터 (값) 세트

302 출력 파라미터 (값) 세트
 400 최적화 기법
 401 목적/적합도 유닛
 IPT 계측 충격 천공 시험
 INC 계측 (V-노치) 샤르피 시험
 TEN 인장 시험
 F_{max} 한계 하중
 $U_{max}F_{max}$ 에서의 처짐
 E_{br} 최대 하중
 σ_y 항복 응력


도면

도면1




도면2


200



도면3a




도면3b




도면4

400




도면5a

천공




도면5b

충격




도면5c

인장




도면6a

천공




도면6b


중적




도면6c




도면7a




도면7b




도면7c




도면7d




도면 8a



도면 8b



도면8c



도면8d

